总 览 · 一 眼 看 完

一场 120 秒的评审会，被拆成了 2 个大段、4 个小点

70.8%
正题
72 秒，占的时间最长

6
知识点条数
归到 2 个一级主题

163
说了多少汉字
分成 6 段

81.5
每分钟说多少字
人声占 84.6%

一 句 话 结 论

这是一份**合成数据**的最小示例，用来演示杂志风报告长什么样、以及「数据自动填 + 文案手写」怎么分工。

它跑通的是**非媒体阶段**：切片 → 大纲合并 → 纠错裁决 → 可读稿 → 统计 → 校验 → 出片。转写与抽帧认字需要真实音视频，见本目录 README。

本 期 目 录

01 120 秒里，过了三个模块

02 样本很小，但每条都算得出

03 纠错为什么要拦一道

04 把示例换成你的视频

120 秒里，过了三个模块

按「在干什么」把这段话切开，归到类型里。示例只有 2 个主题，但表格、占比条、时间线都是**从大纲数据里现算的**——真实长视频只是行数更多。

各类内容各占多久（合计 102s ≈ 00:01:42）

在干什么	#时长	#占比	占比条
正题	72s	**70.8%**	
开场	30s	29.2%	

整场的时间线

主干时间线（时间可点，会跳到那一秒）

从	到	#多久	在干什么	内容
00:00:06	00:00:36	30s	开场	评审范围与登录模块
00:00:36	00:01:48	72s	正题	订单与结算模块的改动与风险

示例数据

花时间最多的几段

单段最长的六块

点了直接看	#多久	在干什么
订单与结算模块的改动与风险	72s	正题
评审范围与登录模块	30s	开场

讲到的要点

- **数据不写死在模板里**：表格里的每一行都来自 `content/outline.json`，改数据不用改模板。
- **文案单独写**：这个文件（`content/magazine-copy.json`）里的句子才是手写的。

> **举个例子（大纲里的一段）：** 「评审范围与登录模块」在 00:00:06–00:00:36（30 秒，2 个点）：
> 00:00:06 本次评审范围只有登录、订单、结算三个模块　00:00:18 登录模块会议纪要已发群，要求未读者补齐

02 • 说 话 统 计

样本很小，但每条都算得出

字数、语速、停顿、提问句、词频、口头禅、领域词命中 —— 示例里数字都很小，但口径与真实长视频完全一样。

说话与节奏（主数字用原始听写稿）

看什么	#数字	说明
分成多少段	6 段	全片 00:02:00
总字数（含标点）	181	
汉字	**163**	
说得多快	**81.5 字/分钟**	
有人说话的时间	101.5s	占 **84.6%**
第一句话在第几秒	6.2s	跳到第一句话
停顿超过阈值次数	1 次	1.5-3 1 次、3-10 0 次、10-30 0 次、>=30 0 次
最长的一次停顿	**1.9s**	在 00:00:36 前后
提问句	0 次	平均每分钟 0.00 次

示例数据

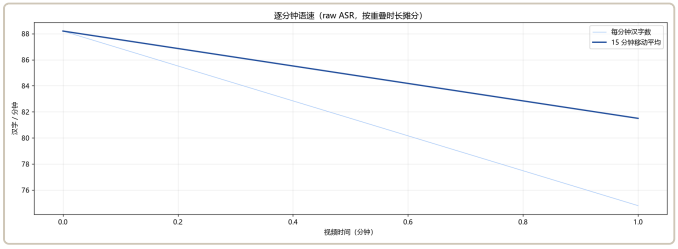


图 1 · 01-逐分钟语速

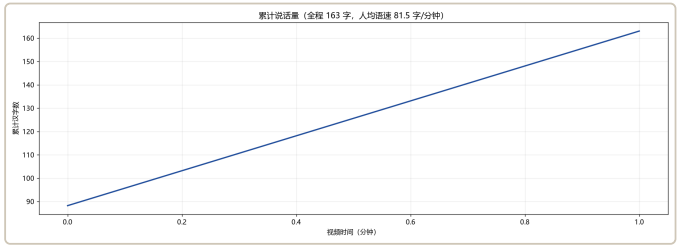


图 2 · 02-累计字数

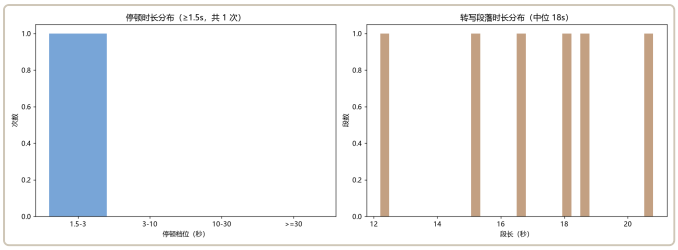


图 3 · 03-停顿与段长

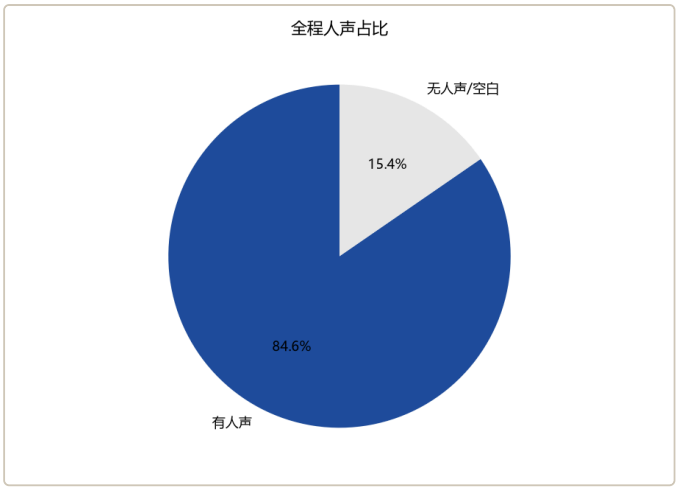


图 4 · 04-人声占比

最常说的词

- 模块 5 次
- 这次 3 次
- 一下 2 次
- 三个 2 次
- 登录 2 次
- 订单 2 次
- 结算 2 次
- 重复 2 次
- 下单 2 次
- 下周 2 次

统计去掉了虚词，完整榜单见 `stats/top-words.csv`。

口头禅

连着说的固定词组，按出现次数排

口头禅	#次数	口头禅	#次数
模块	5	**一个是**	2
这次	3	**一下**	2
三个模块	2	**登录**	2
重复下单	2	**订单**	2
模块的	2	**结算**	2

> **口径提醒：**统计只用原始转写。修正稿与屏幕认字结果**都不参与统计。**

压掉识别复读伪影前后，数字差多少

怎么数	#汉字	#字母数字	#字/分钟
原始稿（报告用的是这个）	**163**	0	**81.50**
压掉重复后（仅作对照）	163	0	81.50

03 · 怎 么 算 的

纠错为什么要拦一道

示例里埋了一个「真词陷阱」：评审→评议 看着像错字，但「评审」本身就是正常词，所以被自动拒绝。

机器听写会重复

原始稿里有 **0 段**出现同一串被重复写成一大串，共移除 0 字。压掉重复后再数一遍，语音密度只差 **0.0%**，所以主数字仍用原始稿。

听写错字是怎么改的（以及哪些没改）

- 先用子代理逐段清点可疑错字，再用词典筛一遍。
- 拿汉语词典查：**错串本身不是词 → 采纳；本身是正常词 → 保守不改**，除非逐条给出理由。
- 最终采纳 **1** 条、拒绝 **1** 条（1 处未改）。
- 校验：改完字数变化 **0**，与预期 **0** 完全一致（只换字、没删改）—— 长度守恒：通过。
- 这份修正稿只给人读，**不参与任何统计。**

几个「看着像错、其实不该改」的例子

本来想改成	结论	为什么
评审 → 评议	**不改**	示例：评审在本文里就是正确用词，明确拒绝替换为「评议」

改动最多的几处：记要→纪要 1 次

- 规则：错串**不是词典词** → 自动采纳；**是词典词** → 默认拒绝，除非逐条给出理由。
- 改完做**长度守恒校验**：字数变化必须等于「替换次数 × 每个串的长度差」，否则说明发生了预期外的改写。

示例数据

- 被拒绝的条目也写进 content/corrections.jsonl，附理由——「为什么没改」和「改了什么」一样重要。

04 · 用 法

把示例换成你的视频

已经能直接做的一些数据调查

想接着往下挖的话，每个问题该翻哪个文件

想问的问题	去哪找数据
想跑真实视频	改 config.json 的 media（BV 号或本地文件），然后 python pipeline.py --stages all
想知道每个数字怎么算的	references/口径模板.md

这些事它做不了

- **示例不能验证转写与认字** —— 那两步需要真实音视频。
- **示例数字没有意义** —— 120 秒合成数据，看流程不看结论。

示例数据

附 · 每个文件里是什么

1. README.md —— 统计口径与复现步骤
2. transcripts —— 原始转写（所有统计的唯一依据）/ 逐字稿 / 修正稿
3. content/outline.json —— 两级内容大纲（主题 + 知识点）
4. content/outline-points.csv —— 知识点长表（Excel / pandas 直接开）
5. content/corrections.jsonl —— 错字逐条记录与裁决结果
6. stats/language-stats.json —— 说话、语速、停顿、词频全量
7. stats/per-minute.csv —— 逐分钟序列
8. stats/top-words.csv —— 词频与领域词命中
9. stats/figures —— 报告里的图表
10. magazine.html —— 本文件（杂志版报告）

示例数据